



T.C.

KIRIKKALE ÜNİVERSİTESİ

MÜHENDİSLİK VE MİMARLIK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

BİTİRME PROJESİ 1

**Parkinson Hastalığının Görüntü İşleme Kullanılarak Makine
Öğrenmesi Algoritmaları ile Tespiti**

Hazırlayan

Veysel DURAN

Danışman

Dr. Öğretim Üyesi Serkan SAVAŞ

12/01/2023

ÖZET

Parkinson hastalığı son zamanlarda ciddi bir sağlık sorunu haline gelmiştir. Etkileri özellikle 65 yaş üstü hastalarda gittikçe artmaktadır. Hastalığın motor aktiviteler üzerindeki olumsuz etkileri hastaları sosyal ortamlardan uzaklaştırmaktadır. Tanısı oldukça zor olan Parkinson hastalığının teşhisinde bilgisayar destekli sistemlerin kullanımı artmaktadır. Parkinson spiral testi ile teşhis bu yöntemlerden biridir. Bu çalışmada, Parkinson hastalığının tanısında çizilen spiraller analiz edilerek Evrişimsel Sinir Ağları kullanılması önerilmektedir.

İÇİNDEKİLER

ÖZET.....	II
İÇİNDEKİLER.....	III
ŞEKİLLER LİSTESİ.....	IV
TABLolar LİSTESİ	V
BÖLÜM 1	1
1.1. GİRİŞ	1
1.2. ÖNCEKİ ÇALIŞMALAR.....	2
BÖLÜM 2	3
2.1. MATERYAL VE METOT.....	3
2.1.1. Veri Seti	3
2.1.2. Evrişimsel Sinir Ağları (CNN)	4
2.1.3. Evrişimsel Sinir Ağı (CNN) Katmanları.....	5
a. Giriş Katmanı (Input Layer)	5
b. Konvolüsyon Katmanı (Convulation Layer)	5
c. Düzleştirilmiş Doğrusal Birim Katmanı(Rectified Linear UnitsLayer(ReLu))	5
d. Havuzlama Katmanı (Pooling Layer).....	5
e. Tam Bağlantılı Katman (Fully Connected Layer)	6
f. DropOut Katmanı	6
g. Sınıflandırma Katmanı(Classification Layer)	6
BÖLÜM 3	7
3.1. ARAŞTIRMA BULGULARI ve TARTIŞMA	7
3.1.1. Deneysel Çalışmalar ve Araştırma Bulguları	7
a. Veri seti hazırlıkları	7
b. CNN model mimarisi.....	9
c. Modelin eğitilmesi ve performansı	10
SONUÇLAR ve ÖNERİLER.....	13
KAYNAKÇA	14
EKLER	15

ŞEKİLLER LİSTESİ

Şekil 1-Evrişimsel sinir ağının genel mimarisi(WILDML 2016)	4
Şekil 2-Standart bir CNN'de DropOut katmanının uygulanması	6
Şekil 3-Sağlıklı İnsanın Spiral Test Çizimi	7
Şekil 4-Parkinson Hastasının Spiral Test Çizimi	8
Şekil 5-CNN Blok Şeması.....	9
Şekil 6-Kullanılan CNN Modeli Özeti	9
Şekil 7-Modelin Doğruluk Parametresi Grafiği	11
Şekil 8-Modelin Hata Oranı Parametresi Grafiği.....	11
Şekil 9-Eğitim Sürecinde İterasyonların İzlenmesi.....	12

TABLÖLAR LİSTESİ

Tablo 1-Verilerin Tablo Üzerinde Gösterilmesi	3
Tablo 2-Spiral Çizimler İçin Veri Büyütme Parametreleri	3
Tablo 3-Verilerden elde edilen ham data	8
Tablo 4-Karışıklık Matrisi.....	10
Tablo 5-Sınıflandırma Parametreleri ve Değerleri	10

BÖLÜM 1

1.1. GİRİŞ

Parkinson hastalığı sinir sistemi üzerindeki olumsuz etkilerini motor reflekslerde yavaşlama, sinirsel aktivitenin azalması ve yaşamsal faaliyetlerde azalma veya kaybolma olarak kendini gösteren, genellikle 65 yaş üstü her 100 kişiden birinde görülen bir hastalıktır.¹

Parkinson hastalığı sinsi başlangıçlıdır ve yıllar içinde tablo giderek ağırlaşır. Hastalık erken döneminde (prodrom) çabuk yorulma, güçsüzlük hissi, halsizlik, yazma zorluğu gibi belirtiler göstermektedir. Hastaneye başvuran hastaların katılık, ağrılar, yazma güçlüğü gibi sebeplerden hastaneye başvurdıkları gözlenmektedir. Bu evrede tanı konulması oldukça zor olup genellikle aylar hatta yıllar sonra hastalığın her bölgede belirtilerinin ortaya çıkması ile tanı konulmaktadır.²

Hastalığın tedavisinde erken evrede vücudun dopamin seviyesini arttırmak için kullanılan levodopa ilacı ilk evrelerde kullanılırken hastalığın ilerleyen evrelerinde yan etkiler göstermektedir. İlaç etkisini kaybettiğinde veya erken tanı yapılamama durumunda cerrahi müdahale gerekmektedir.³

Parkinson hastalığının görülme sıklığı, teşhis zorluğu, aynı zamanda erken teşhisinin önemi göz önüne alındığında bu zorlu sürecin bir miktar da olsa kolaylaştırılması amacıyla yapay zekâ ve makine öğrenmesi algoritmalarının Parkinson hastalığının tanı ve teşhisinde kullanılması büyük önem arz etmektedir.

Bu çalışmada Parkinson tanısında uzman görüşlerini desteklemek ve doğruluk oranının artırılması hedeflenmektedir. Literatürde yapılan çalışmalar incelendiğinde spiral görseller üzerinden yapılan Parkinson teşhisinde elde edilen görseller ile olması gereken görseller arasındaki farkın karşılaştırılması yöntemine başvurulmuştur. Bu çalışmada ise her görsel (spiral) bir karakter olarak tanımlanmış ve Evrişimsel Sinir Ağları (CNN) kullanılarak başarılı sonuçlar elde edilmiştir.

¹ Özdemir, H. (Editor), (2022). Parkinson Hastalığı "Geçmişten Geleceğe" - 2022 . Ankara: Türkiye Klinikleri Yayınevi sy.(1-2).

² Çakmur, R. (2011). Parkinson hastalığı ve medikal tedavisi. *Klinik Gelişim*, 53, 58.

³ Güler, S., Caylan, A., Turan, F. N., & Dağdeviren, N. (2022). Batı Türkiye'de İdiyopatik Parkinson Hastalığının Prevalansı ve Klinik Özellikleri. *Noro-Psikiyatri Arsivi*, 59(2), 98-104.

1.2. ÖNCEKİ ÇALIŞMALAR

Yapılan çalışmalarda hastalığın belirtileri göz önüne alındığında özellikle çizim, el yazısı, konuşma ve yürüyüş özellikleri incelenmiştir.

Hastalarda kişilik değişimleri ve çabuk yorulmalar gözlemlendikten sonra motor belirtiler gözlenmeye başlar. Hastaların şikayetleri kol ve omuz ağrıları üzerinde yoğunlaşmaktadır. Kolları az sallayarak yürümek ve ellerde titreme semptomu hastalık teşhisi için dikkat edilmesi gereken saptamalardandır.⁴

Parkinson hastalığının ses yapısı üzerindeki etkilerinden olan ses bozulmalarını ölçerek hastalık durumunu derecelendirmeyi hedefleyen çalışmada 23'ü hasta olmak üzere 31 denek kullanılmıştır. Deneklere konuşma testleri uygulanmış ve sesteki titreşim, ton ve ses düzeyi gibi özellikler tespit edilmiştir. Elde edilen verilerden hangilerinin hastalık durumunu belirlemede kullanılabileceği belirlenmiş ve belirlenen özellikler üzerinden kişinin hastalığın hangi aşamada olduğunu %94 oranında başarılı bir şekilde tespit etmişlerdir.⁵

Yapılan başka bir çalışmada el yazısı görüntülerinin özelliklerinin öğrenmek için evrimsel sinir ağlarını tanıtmışlardır. Parkinson hastalığının teşhisi üzerine yapılan ve yapılacak olan çalışmaları teşvik etmek amacıyla elde ettikleri veriyi kullanıma sunmuşlardır. Erken evre tespitinde %95 oranında başarımla elde ederek klasik teşhis yöntemlerine göre daha iyi performans elde edilebildiğini göstermişlerdir.⁶

Luciano ve ark. (2016) 138 Parkinson olmak üzere 150 kişiye verilen tabletler üzerine spiraller çizdirerek x, y, z koordinat verileri, basınç ve zaman bilgilerini toplamışlardır. İkinci dereceden düzgünlük, birinci dereceden sıfır geçiş, şekil ve kinematik düzensizlikler, sıkılık, ortalama hız ve spiral genişlik gibi endeksleri araştırmışlardır. Sıfır geçişi dışında tüm endekslerin denekler arasında anlamlı olarak farklı olduğunu tespit etmişlerdir.⁷

⁴ DELİL, Ş., 2001, Parkinson Hastalığında Levodopa'ya Bağlı Motor Komplikasyonların Gelişmesinde Rol Oynayan Etkenler, Uzmanlık Tezi. İstanbul Üniversitesi.

⁵ LITTLE, M.A., MCSHARRY, P.E., HUNTER, E.J., SPIELMAN, J., RAMIG, L.O., 2009. Suitability of Dysphonia Measurements for Telemonitoring of Parkinson's Disease. IEEE Transactions on Biomedical Engineering, 56(4); 1015-1022.

⁶ PEREIRA, C. R., PEREIRA, D. R., Rosa, G. H., ALBUQUERQUE, V. H. C., WEBER, S. A. T., HOOK, C. and Papa, J. P. (2018). Handwritten dynamics assessment through convolutional neural networks: An application to Parkinson's disease identification. Artificial Intelligence in Medicine, 87, 67– 77.

⁷ SAN LUCIANO, M., WANG, C., ORTEGA, R. A., YU, Q., BOSCHUNG, S., SOTOVALENCIA, J. and SAUNDERS-PULLMAN, R., 2016. Digitized spiral drawing: A possible biomarker for early Parkinson's disease. PLoS ONE, 11(10), 1–11.

BÖLÜM 2

2.1. MATERİYAL VE METOT

2.1.1. Veri Seti

Veri seti Kaggle⁸ üzerinden indirilmiş olup Zham ve Kumar(2017)⁹ tarafından yayınlanmıştır. 51 sağlıklı ve 51 hasta çizimi olmak üzere 102 çizim verisi bulunmaktadır. Elde edilen spiral çizim verileri matrislere çevrilerek .npz dosyaları ile programda kullanılmak üzere hazırlanmıştır. Bu verilerin %70'i eğitim %30'u ise test verisi olarak ayrılmıştır.

	Sağlıklı Spiral Görseller	Parkinson Spiral Görseller
Eğitim Verileri	36 adet	36 adet
Test Verileri	15 adet	15 adet

Tablo 1-Verilerin Tablo Üzerinde Gösterilmesi

Veri setinde görüntü sayısının oldukça az olması sebebiyle CNN uygulanması zorlaşmaktadır. Bu nedenle eğitim veri setine bazı sentetik örnekler eklenerek veri setindeki çeşitliliğin artırılması için veri büyütme yapılmıştır.

Büyütme Parametreleri	Değerler
Yatay Döndürme	True
Dikey Döndürme	True
Genişlik Kaydırma Aralığı	0.1
Yükseklik Kaydırma Aralığı	0.1
Parlaklık Aralığı	(0.5,1.5)
Döndürme Aralığı	360

Tablo 2-Spiral Çizimler İçin Veri Büyütme Parametreleri

⁸ <https://www.kaggle.com/datasets/kmader/parkinsons-drawings>


⁹ Zham P, Kumar DK, Dabnichki P, Poosapadi Arjunan S and Raghav S (2017) Distinguishing Different Stages of Parkinson's Disease Using Composite Index of Speed and Pen-Pressure of Sketching a Spiral. Front. Neurol. 8:435. doi: 10.3389/fneur.2017.00435

2.1.2. Evrişimsel Sinir Ağları (CNN)

Makine öğrenmesi mevcut veriler yardımıyla elde edilen tecrübelerin bilgisayar yazılımları ile gelecekteki olayları tahmin etmede ve modelle yapılmasına olanak sağlayan yapay zekâ alanıdır. Temel dayanağı giriş bilgilerini alan algoritmalar yardımıyla çıktılar oluşturmaktır ve bu çıktıları yeni veriler ile güncelleyip yeni bir çıktıyı tahmin etmek için istatistiksel analizler kullanılmaktadır. Makine öğrenmesinin gelişimi hızla artarken bu yönde çok sayıda algoritma geliştirilmektedir.

Denetimli ve denetimsiz algoritmalar olarak makine öğrenme algoritmaları kategorize edilir. Algoritmalar eğitim sırasında yapılan tahminlerin doğruluğunu teyit etmenin yanında, hem girdileri hem de çıktıları sağlamak için bir veri bilimcisi veya veri analisti gerektirir. Modelde hangi değişkenlerin kullanılacağını, modelin hangi özellikleri analiz edeceğini veri bilimci belirler. Eğitim sonunda algoritmanın öğrendikleri yeni verilere uygulanır.

Bu projede kullanılan CNN algoritması 7 katmandan oluşur. Bu katmanlar sırasıyla Giriş Katmanı (Input Layer), Konvolüsyon Katmanı (Convulation Layer), Düzleştirilmiş Doğrusal Birim Katmanı(Rectified Linear UnitsLayer(ReLU)), Havuzlama Katmanı (Pooling Layer), Tam Bağlantılı Katman (Fully Connected Layer), DropOut Katmanı, Sınıflandırma Katmanı(Classification Layer) olarak adlandırılır. CNN’de görüntü sınıflandırma işlemleri sırasında pikseller kenar kombinasyonlarından oluşan motifleri, bu motifleri birleştirerek nesne parçalarını ve nesne parçalarını birleştirerek nesneleri oluşturur.



Şekil 1-Evrişimsel sinir ağının genel mimarisi(WILDML 2016)¹⁰

¹⁰ WILDML. (2016). "UNDERSTANDING CONVOLUTIONAL NEURAL NETWORKS FOR NLP." from <http://www.wildml.com/2015/11/understanding-convolutional-neural-networks-for-nlp/>

2.1.3. Evrişimsel Sinir Ağı (CNN) Katmanları

a. Giriş Katmanı (Input Layer)

Bu katman ilk katman olarak görev yapmaktadır. Bu katmanda veri ham olarak ağa verilmektedir. Tasarlanacak modelin başarımı için bu katmandaki verinin boyutu önem kazanmaktadır. Giriş görüntü boyutunun yüksek seçilmesi hem yüksek bellek ihtiyacını hem eğitim süresini hem de görüntü başına düşen test süresini uzatabilir. Bunun yanında ağ başarısını arttırabilir. Giriş görüntü boyutunun düşük seçilmesi bellek ihtiyacını azaltır ve eğitim süresini kısaltır. Fakat kurulacak ağın derinliği azalır ve performansı düşük olabilir. Görüntü analizinde hem ağ derinliği hem donanımsal hesaplama maliyeti hem de ağ başarısı için uygun bir giriş görüntü boyutu seçilmelidir.

b. Konvolüsyon Katmanı (Convolution Layer)

Bu katman dönüşüm katmanı olarak da bilinir. Bu dönüşüm işlemi belirli bir filtrenin tüm görüntü üzerinde dolaştırılması işlemine dayanmaktadır. Bu sebeple filtreler katmanlı mimarinin ayrılmaz bir bileşenidir. Filtreler 2x2, 3x3, 5x5 gibi farklı boyutlarda olabilir. Filtreler, bir önceki katmandan gelen görüntülere konvolüsyon işlemini uygulayarak çıkış verisini oluştururlar. Bu konvolüsyon işlemi sonucu Özellik haritası oluşur. Özellik haritası, her bir filtreye özgü özelliklerin keşfedildiği bölgelerdir. Modellerin eğitimi esnasında bu filtrelerin katsayıları, eğitim kümesindeki her öğrenme yinelemesiyle değişir. Böylelikle ağ, özelliklerin belirlenmesi için, verinin hangi bölgelerinin önem taşıdığını belirler.

c. Düzleştirilmiş Doğrusal Birim Katmanı(Rectified Linear UnitsLayer(ReLU))

Bu katman aynı zamanda aktifleştirme katmanı olarakta bilinir. Giriş verisine yapmış olduğu etki negatif değerleri sıfıra çekmesidir. Bu katmandan önce kullanılan konvolüsyon katmanında belirli matematiksel işlemler yapıldığı için ağ doğrusal bir yapıdadır. Bu derin ağı doğrusal olmayan bir yapıya sokmak için bu katman uygulanır. Bu katmanın kullanılması ile ağ daha hızlı öğrenir. Matematiksel olarak (1)'deki gibi tanımlanmaktadır.

$$f(x) = \begin{cases} 0 & \text{eğer } x < 0 \\ x & \text{eğer } x \geq 0 \end{cases} \quad (1)$$

d. Havuzlama Katmanı (Pooling Layer)

Bu katmanın temel amacı, sonraki konvolüsyon katmanı için giriş boyutunu (Genişlik x Yükseklik) azaltmaktır. Bu filtreler görüntü üzerinde belli bir adım atma değerine göre gezdirilerek görüntüdeki piksellerin maksimum değerlerini (maksimum havuzlama) veya değerlerin ortalamasını (ortalama havuzlama) alarak işlem yapılır. Genellikle maksimum


havuzlama, daha iyi performans gösterdiği için tercih edilir. Havuzlama işlemi, konvolüsyon katmanı sonucu oluşan filtre adedince görüntülerin hepsi için gerçekleştirilir.

e. Tam Bağlantılı Katman (Fully Connected Layer)

Bu katman art arda gelen konvolüsyon, ReLu ve havuzlama katmanından sonra tam bağlantılı katman gelir. Bu katman kendinden önceki katmanın tüm alanlarına bağlıdır. CNN mimarisinde en son katmanın üretmiş olduğu matris boyutu $25 \times 25 \times 256 = 160000 \times 1$ ve tam bağlantılı katmandaki matris boyutu 4096×1 olarak seçilirse. Toplamda 160000×4096 ağırlık matrisi oluşur. Yani her bir 160000 nöron 4096 nöron ile bağlanmaktadır. Bu sebepten dolayı bu katmana tam bağlantılı katman denilmektedir.

f. DropOut Katmanı

CNN'de büyük veriler ile eğitim işlemi yapıldığı için bazen ağ ezberleme yapar. Ağın ezberlemesinin önüne geçmek için bu katman kullanılır(Srivastava, Hinton et al. 2014).¹¹ Bu katmanda uygulanan temel mantık ağın bazı düğümlerinin kaldırılmasıdır.



Şekil 2-Standart bir CNN'de DropOut katmanının uygulanması¹²

g. Sınıflandırma Katmanı(Classification Layer)

Bu katman tam bağlantılı katmandan sonra gelir. Derin öğrenme mimarilerinin bu katmanında sınıflandırma işlemi yapılmaktadır. Bu katmanın çıkış değeri, sınıflandırması yapılacak nesne sayısına eşittir. Örneğin 2 farklı nesnenin sınıflandırılması yapılacaksa, sınıflandırma katmanı çıkış değeri 2 olmalıdır.

¹¹ Srivastava, N., G. E. Hinton, A. Krizhevsky, I. Sutskever and R. Salakhutdinov (2014). "Dropout: a simple way to prevent neural networks from overfitting." Journal of machine learning research 15(1): 1929- 1958.

¹² Özkan, İ. N. İ. K., & Ülker, E. (2017). Derin öğrenme ve görüntü analizinde kullanılan derin öğrenme modelleri. Gaziosmanpaşa Bilimsel Araştırma Dergisi, 6(3),94.


BÖLÜM 3

3.1. ARAŞTIRMA BULGULARI ve TARTIŞMA

3.1.1. Deneysel Çalışmalar ve Araştırma Bulguları


a. Veri seti hazırlıkları

Kaggle üzerinden alınan verilerin büyütüldüğünden bahsetmiştik. Bu veriler programın eğitim süresinin hızlandırılması amacıyla Numpy Array türünde dizi haline getirilmiştir. Şekil-3,4'te sağlıklı ve Parkinson hastalığına sahip bireylerin spiral test çizimleri verilmiştir. Çizim verilerinden elde edilen ham veri seti Tablo-3'te verilmiştir.



Şekil 3-Sağlıklı İnsanın Spiral Test Çizimi

Spiral Drawing by a Person having Parkinson's Disease



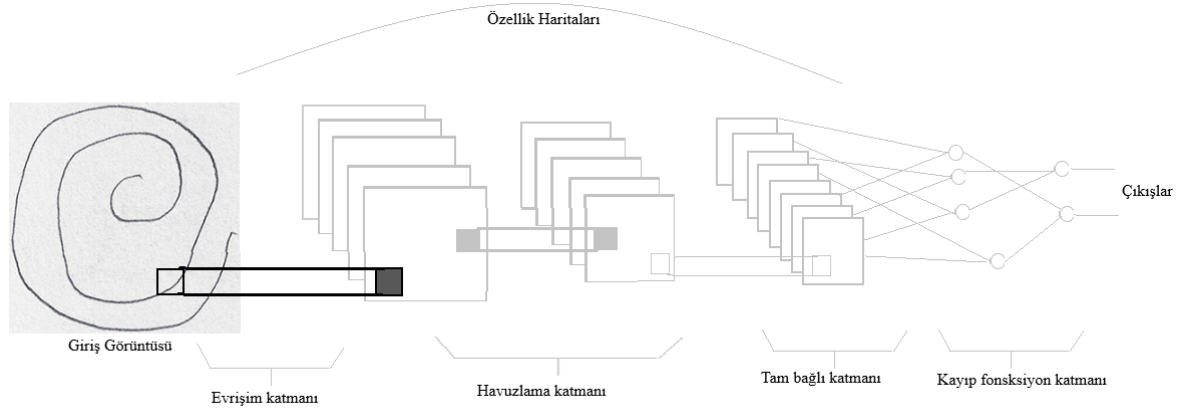
Şekil 4-Parkinson Hastasının Spiral Test Çizimi

```
[[[ [243 243 243]    [ [242 242 242]
   [242 242 242]    [253 253 253]
   [243 243 243]    [245 245 245]
   ...              ...
   [237 237 237]    [237 237 237]
   [239 239 239]    [229 229 229]
   [240 240 240]] ..... [238 238 238]]]]
```

Tablo 3-Verilerden elde edilen ham data

Elde edilen veri seti test ve eğitim verileri olarak ayrı iki dosyada saklanmak üzere kaydedilmiştir. Bu veri setindeki değerler kullanılarak CNN algoritması eğitime çalışılmış ve bu eğitim sonucunda test verileri ile tahmin işlemleri yapılarak sistemin performans parametreleri hakkında bilgi edinilmiştir.

b. CNN model mimarisi



Şekil 5-CNN Blok Şeması

Kullanılan model sırasıyla 128, 64, 32 ve 32 filtrelili 4 evrişim katmanı içerir. Bu katmanlar değişken filtre boyutlarına sahip filtreler içerirler. Her evrişim katmanını bir havuzlama katmanı takip eder. Tam bağlı katman evrişim bloğunu takip eder. Model keras ile tanımlanmış olup model özellikleri Şekil-6'da verildiği gibidir.

Model: "sequential"

Layer (type)	Output Shape	Param #
conv1 (Conv2D)	(None, 128, 128, 128)	3328
max_pooling2d (MaxPooling2D)	(None, 40, 40, 128)	0
conv2 (Conv2D)	(None, 40, 40, 64)	204864
max_pooling2d_1 (MaxPooling2D)	(None, 12, 12, 64)	0
conv3 (Conv2D)	(None, 12, 12, 32)	18464
max_pooling2d_2 (MaxPooling2D)	(None, 4, 4, 32)	0
conv4 (Conv2D)	(None, 4, 4, 32)	9248
max_pooling2d_3 (MaxPooling2D)	(None, 1, 1, 32)	0
flatten (Flatten)	(None, 32)	0
dropout (Dropout)	(None, 32)	0
fc1 (Dense)	(None, 64)	2112
dropout_1 (Dropout)	(None, 64)	0
fc3 (Dense)	(None, 2)	130
=====		
Total params: 238,146		
Trainable params: 238,146		
Non-trainable params: 0		

Şekil 6-Kullanılan CNN Modeli Özeti

c. Modelin eğitilmesi ve performansı

Kullanılan model eğitilirken iterasyon sayısı 70 ve küme büyüklüğü 128 olarak belirlenmiştir. Eğitilen model test verileriyle test edilerek çizilen spiral görselleri üzerinden kişinin hasta olup olmadığını tespit etmeye hazır hale gelmiştir.

Hastalığın tespitinde modelin başarısını değerlendirmek için Duyarlılık, Özgüllük, Doğruluk ve Hassasiyet parametreleri kullanılmaktadır. Bu parametrelerin hesaplanabilmesi için karışıklık matrisinin; Doğru Pozitif (TP), doğru olarak tahmin edilen hasta sayısı, yanlış bir şekilde hasta olarak tahmin edilen hasta olmayan kişiler Yanlış Pozitif (FP), Hasta olarak tahmin edilmeyen hastaların sayısı ise Yanlış Negatif (FN) ve hasta olmadığı tahmin edilen hasta olmayan kişilerin sayısı ise Doğru Negatif (TN) olmak üzere 4 adet parametre de hesaplanmıştır.

		Tahmin Değerleri	
		YOK	VAR
Gerçek Değerler	YOK	254	61
	VAR	29	286

Tablo 4-Karışıklık Matrisi

Tablo 4'teki karışıklık matrisi üzerinden c.1,2,3,4,5'teki parametreler hesaplanmıştır. Başarı parametreleri Tablo 5'te gösterilmiştir.

$$\text{Duyarlılık} = \frac{TP}{TP+FN} = 0,90 \quad (\text{c.1.})$$

$$\text{Doğruluk} = \frac{TP+TN}{TP+TN+FP+FN} = 0,86 \quad (\text{c.2.})$$

$$\text{Özgüllük} = \frac{TN}{FP+TN} = 0,81 \quad (\text{c.3.})$$


$$\text{Hassasiyet} = \frac{TP}{TP+FP} = 0,82 \quad (\text{c.4.})$$

$$\text{Hata Oranı} = \frac{FN+FP}{TP+TN+FP+FN} = 0,14 \quad (\text{c.5.})$$


Parametreler	Duyarlılık	Doğruluk	Özgüllük	Hassasiyet	Hata Oranı
Değerler	0,90	0,86	0,81	0,82	0,14

Tablo 5-Sınıflandırma Parametreleri ve Değerleri

Modelin doğruluk performans metriğinin ve hata oranı performans metriğinin grafik üzerinde gösterilmesi de Şekil-7,8’de verilmiştir.



Şekil 7-Modelin Doğruluk Parametresi Grafiği



Şekil 8-Modelin Hata Oranı Parametresi Grafiği


```

Epoch 1/70
40/40 [=====] - 538s 13s/step - loss: 0.8518 - accuracy: 0.5061 - val_loss: 0.8477 - val_accuracy: 0.5000
Epoch 2/70
40/40 [=====] - 545s 14s/step - loss: 0.8448 - accuracy: 0.5000 - val_loss: 0.8409 - val_accuracy: 0.5000
Epoch 3/70
40/40 [=====] - 570s 14s/step - loss: 0.8376 - accuracy: 0.5127 - val_loss: 0.8338 - val_accuracy: 0.5000
Epoch 4/70
40/40 [=====] - 583s 15s/step - loss: 0.8317 - accuracy: 0.5088 - val_loss: 0.8279 - val_accuracy: 0.5000
Epoch 5/70
40/40 [=====] - 551s 14s/step - loss: 0.8259 - accuracy: 0.4975 - val_loss: 0.8228 - val_accuracy: 0.5000
Epoch 6/70
40/40 [=====] - 428s 11s/step - loss: 0.8202 - accuracy: 0.5198 - val_loss: 0.8168 - val_accuracy: 0.5000
Epoch 7/70
40/40 [=====] - 425s 11s/step - loss: 0.8152 - accuracy: 0.5067 - val_loss: 0.8113 - val_accuracy: 0.7508
Epoch 8/70
40/40 [=====] - 423s 11s/step - loss: 0.8103 - accuracy: 0.5129 - val_loss: 0.8068 - val_accuracy: 0.5000
Epoch 9/70
40/40 [=====] - 426s 11s/step - loss: 0.8056 - accuracy: 0.5166 - val_loss: 0.8017 - val_accuracy: 0.5540
.
.
.
Epoch 67/70
40/40 [=====] - 412s 10s/step - loss: 0.3881 - accuracy: 0.8775 - val_loss: 0.4388 - val_accuracy: 0.8524
Epoch 68/70
40/40 [=====] - 417s 10s/step - loss: 0.3870 - accuracy: 0.8797 - val_loss: 0.4429 - val_accuracy: 0.8444
Epoch 69/70
40/40 [=====] - 417s 10s/step - loss: 0.3767 - accuracy: 0.8879 - val_loss: 0.4327 - val_accuracy: 0.8587
Epoch 70/70
40/40 [=====] - 419s 10s/step - loss: 0.3872 - accuracy: 0.8713 - val_loss: 0.4266 - val_accuracy: 0.8571

```

Şekil 9-Eğitim Sürecinde İterasyonların İzlenmesi

Elde edilen sonuçlar 1.80 GHz Intel i5 işlemci, 8 GB RAM bulunan bir bilgisayarda gerçekleştirilmiştir. Python programlama dili ile Jupyter Notebook program ortamında algoritmalar kodlanmıştır. Model 70 iterasyon çalıştırılmış ve eğitim süresi yaklaşık 10 saattir. Bu şartlarda alınan sonuçlar Tablo-4,5 ve Şekil-7,8’de verilmiştir.

SONUÇLAR ve ÖNERİLER

Parkinson hastalığının teşhisinin de zor olması, teşhis için yardımcı araçlara olan ihtiyacı arttırmaktadır. Bilgisayar yardımıyla Parkinson hastalığının teşhisine yardımcı olmak için günümüzde çeşitli çalışmalar yapılmakta olup bu çalışma ile Parkinson hastalığının teşhisinde spiral test çiziminin katkısının olabilirliği araştırılmıştır.

Elde edilen veriler ve geliştirilen model ile %86 başarımla Parkinson hastalığı bireylerin çizimleri üzerinden tespit edilmektedir.

Her iterasyonda modelin hata oranındaki düşüşün göz önüne alınması, iterasyon sayısının artırılmasıyla hata oranının düşmesi ve doğruluk oranının yükseleceğini düşündürmektedir. Bu sebeple modelin iterasyon sayısının arttırılabilir ve tekrar eğitilerek daha iyi sonuçlar elde edilebilir.

Veri setinin genişletilmesi ile model performansının artacağını da söyleyebiliriz.

KAYNAKÇA

Özdemir, H. (Editor), (2022). Parkinson Hastalığı "Geçmişten Geleceğe" - 2022 . Ankara: Türkiye Klinikleri Yayınevi sy.(1-2).

Çakmur, R. (2015). Parkinson Hastalığı ve Medikal Tedavisi. Klinik Gelişim. 2010; 1: 53-60. 273 Marmara Üniversitesi Sağlık Bilimleri Enstitüsü Dergisi Cilt: 5, Sayı: 4, 2015. Journal of Marmara University Institute of Health Sciences, 5(4).

Güler, S., Caylan, A., Turan, F. N., & Dağdeviren, N. (2022). Batı Türkiye'de İdiyopatik Parkinson Hastalığının Prevalansı ve Klinik Özellikleri. Noro-Psikiyatri Arsivi, 59(2), 98-104.

DELİL, Ş., 2001, Parkinson Hastalığında Levodopa'ya Bağlı Motor Komplikasyonların Gelişmesinde Rol Oynayan Etkenler, Uzmanlık Tezi. İstanbul Üniversitesi.

LITTLE, M.A., MCSHARRY, P.E., HUNTER, E.J., SPIELMAN, J., RAMIG, L.O., 2009. Suitability of Dysphonia Measurements for Telemonitoring of Parkinson's Disease. IEEE Transactions on Biomedical Engineering, 56(4); 1015-1022.

PEREIRA, C. R., PEREIRA, D. R., Rosa, G. H., ALBUQUERQUE, V. H. C., WEBER, S. A. T., HOOK, C. and Papa, J. P. (2018). Handwritten dynamics assessment through convolutional neural networks: An application to Parkinson's disease identification. Artificial Intelligence in Medicine, 87, 67– 77.

SAN LUCIANO, M., WANG, C., ORTEGA, R. A., YU, Q., BOSCHUNG, S., SOTOVALENCIA, J. and SAUNDERS-PULLMAN, R., 2016. Digitized spiral drawing: A possible biomarker for early Parkinson's disease. PLoS ONE, 11(10), 1–11.

<https://www.kaggle.com/datasets/kmader/parkinsons-drawings>

Zham P, Kumar DK, Dabnichki P, Poosapadi Arjunan S and Raghav S (2017) Distinguishing Different Stages of Parkinson's Disease Using Composite Index of Speed and Pen-Pressure of Sketching a Spiral. Front. Neurol. 8:435. doi: 10.3389/fneur.2017.00435

WILDML. (2016). "UNDERSTANDING CONVOLUTIONAL NEURAL NETWORKS FOR NLP." from <http://www.wildml.com/2015/11/understanding-convolutional-neural-networks-for-nlp/>

Srivastava, N., G. E. Hinton, A. Krizhevsky, I. Sutskever and R. Salakhutdinov (2014). "Dropout: a simple way to prevent neural networks from overfitting." Journal of machine learning research 15(1): 1929- 1958.

Özkan, İ. N. İ. K., & Ülker, E. (2017). Derin öğrenme ve görüntü analizinde kullanılan derin öğrenme modelleri. Gaziosmanpaşa Bilimsel Araştırma Dergisi, 6(3),94.

EKLER

Aşağıdaki link üzerinden kod dokümanına ve veri setlerine erişebilirsiniz.

<https://drive.google.com/file/d/10vtVLdzt4kDKy91JPRIB3bCuDfOJaJiN/view?usp=sharing>